

Лабораторная работа № 1 по курсу дискретного анализа: сортировка за линейное время

Выполнил студент группы 08-208 МАИ *Куликов Алексей*.

Условие

1. Необходимо разработать программу, осуществляющую ввод пар "ключ-значение" упорядочивание их в порядке возрастания указанным далее алгоритмом сортировки за линейное время, и вывод отсортированной последовательности.
2. Вариант задания: 7-2. В качестве ключа используются автомобильные номера в формате А 999 ВС (используются буквы латинского алфавита), в качестве значения – строки переменной длины (до 2048 символов).

Метод решения

Алгоритм поразрядной сортировки основан на распределении записей по неким спискам. Распределение производится поразрядно: сначала записи распределяются согласно значениям одного крайнего разряда, и элементы группируются по результатам этого распределения, затем сравниваются значения следующего разряда, соседнего, и элементы либо упорядочиваются по результатам сравнения значений этого разряда внутри образованных на предыдущем проходе групп, либо переупорядочиваются в целом, но сохраняя относительный порядок, достигнутый при предыдущей сортировке. Затем аналогично делается для следующего разряда, и так до конца. Таким образом на каждом этапе элементы последовательности постепенно занимают положенное им место в отсортированной последовательности.

Описание программы

Программа состоит из нескольких файлов:

В заголовочном файле `radix.hpp` реализован функционал поразрядной сортировки и подсобных функций, необходимых для ее работы.

Поразрядная сортировка в ходе работы использует такую структуру данных, как очередь, реализация которой находится в заголовочном файле `queue.hpp`.

Для удобства обработки предусмотрен тип данных `TRecord`, хранящий указатели на ключ и значение записи. Его реализация, а так же функции чтения и формирования записей расположены в заголовочном файле `record.hpp`.

Для хранения записей реализовано некое подобие вектора из стандартной библиотеки шаблонов, выполняющее его основные функции. Реализация находится в заголовочном файле `vector.hpp`. Все выше перечисленное непосредственно участвует в работе программы, находящейся в `main.cpp`.

Дневник отладки

1. 19.09 17:30. Некорректный ввод (создается лишняя запись, с ключом, таким же как и у последней записи на входе, но с пустым значением).

РЕШЕНИЕ: изучив описания функций пришел к выводу, что `cin.getline` выбрасывает `cin.fail`, если он наткнулся на конец файла, до прочтения `N` запрошенных символов, либо до того, как наткнется на разделитель. (См. код `record.hpp` `ReadRecord`)

2. 19.09 18:50. Возникла потребность в независимости от количества входных данных на входе, т.к. не всегда можно указать заведомо большее число.

РЕШЕНИЕ: реализация простейшего вектора. (См. код `vector.hpp`)

3. 20.09 18:20. Возникла потребность в "хранилищах" для поразрядной сортировки записей.

РЕШЕНИЕ: реализация простейшей очереди на динамических структурах. (См. код `queue2.hpp`)

4. 20.09 19:40. Не правильно обрабатываются пустые строки на входе.

РЕШЕНИЕ: пока следующий символ в потоке `\n`, считываем его. (См. код `main.cpp` `main`)

5. 20.09 20:00. Отправил на чекер, понял, что медленно. Принял решение отказаться от красивого кода.

РЕШЕНИЕ: Назначил функцию сортировки дружественной к классу вектора. Сработало. ОК на чекере. (См. код `vector.hpp`)

6. 21.09 17:00. Начал писать бенчмарк для алгоритма. Не работает стандартная быстрая сортировка на стандартном векторе.

РЕШЕНИЕ: исправить глупые ошибки с приведением указателей. (См. код `main.cpp` `main` (бенчмарк))

7. 21.09 19:20. Сравнение скорости работы алгоритмов. Поразрядная сортировка моей реализации проигрывает стандартной быстрой в 3,5 раза.

РЕШЕНИЕ: Анализируем, ищем "слабые места". Прихожу к выводу что простая очередь слишком медленная т.к. на каждую вставку/удаление нужен системный вызов (долго). Создаем новую реализацию очереди. (См. код `queue.hpp`)

8. 21.09 19:50. Утечка памяти в новой очереди.


РЕШЕНИЕ: Долго ищу почему и как. Меняю `delete[]` на `delete` (См. код `queue.hpp`)

9. 21.09 21:20. Поразрядная сортировка моей реализации все равно проигрывает стандартной быстрой, но уже в 1,45 раза.

РЕШЕНИЕ: Упростить алгоритм сортировки. (См. код `radix.hpp` `RadixSort`)

Замеры проводились с помощью созданного бенчмарка.

Тест производительности



По оси X отмечено количество данных, по оси Y – время в миллисекундах. Как можно видеть, график почти линейный.

Недочёты

Существуют более совершенные методы решения данной задачи, а так же более совершенные структуры данных, для ее решения, которые я, к сожалению, не смог реализо-

вать.

Выводы

Данный алгоритм, естественно, при должной реализации, имеет множество применений в практическом программировании. В силу своей скорости выполнения, вполне может применяться в областях программирования, работающих с большими объемами данных.

Например, существует государственная база данных, сохраняющая списки автомобилей. Здесь в качестве ключа может выступать, например, дата последнего участия в ДТП. И, таким образом, страховая компания может понять для себя риски в страховании того или иного человека.

Данный алгоритм в своем простейшем виде довольно прост для реализации, однако существуют, более сложные для написания реализации, но работающие заметно лучше. Так же можно найти незначительные улучшения в частных случаях работы алгоритма (как раз на примере автомобильных номеров в качестве ключей), что, впрочем, мне не очень-то удалось.

В ходе работы над данной задачей, основные трудности возникли с реализацией более оптимальных структур данных, для промежуточного хранения, не сильно замедляющих алгоритм частыми системными вызовами для аллокации памяти на куче.